03. 데이터 정제 - 결측값(NaN)처리

```
df.dropna(how='all')            # 모든게 결측값인거 dropna시킴
df.dropna(how='any')            # 어느거 하나라도 결측값인거 dropna시킴
df.fillna(value=5.0)            # 결측값 대체 # 값이 하나일땐 value를 안써도됨
df.isnull()                     # isnull() : 결측값입니까?  True or False  <-> notnull()
df.loc[df.isnull()['E'], :]     # 'E'열에서 결측값을 가지고 있는 로우만 추출
```

04. 계층적 인덱싱 (다중인덱싱)

```
df.dropna(how='all')            # 모든게 결측값인거 dropna시킴  cf. how='any'

# set_index() : 리스트 형식으로, 계층순서대로 컬럼명을 주면 컬럼에 따라 인덱스가 바뀜
df3 = df2.set_index(['c','d'])          # c,d열이 인덱스로 가고, 데이터는 사라짐
df2.set_index(['c','d'], drop=False)    # c,d열이 인덱스로 가지만, 데이터는 남아있음
df3.reset_index()               # 인덱스 취소

df4.index.name = 'city'         # 인덱스, 컬럼에 제목넣기
df4.columns.name = 'number'     # names-> 인덱스 여러개일 때
```

number	one	two	three
city			
Seoul	0	1	2
Busan	3	4	5

```
df4.stack()                     # 시리즈형태로 바뀜  <-> unstack()
```

city	number	
Seoul	one	0
	two	1
	three	2
Busan	one	3
	two	4
	three	5

```
pd.merge(df1, df2, on='key', how='outer')    # df1, df2 합침 (how='outer' 모든 키값 보여줌)
pd.merge(df1, df2, on='key', how='left')     # 왼쪽에 있는 행은 고정. / df1의 key값 // (오른쪽(df2)은 없으면 제거됨..)
```

	key	data1
0	b	0
1	b	1
2	a	2
3	c	3
4	a	4
5	a	5
6	b	6

	key	data2
0	a	0
1	b	1
2	d	2

	key	data1	data2
0	b	0.0	1.0
1	b	1.0	1.0
2	b	6.0	1.0
3	a	2.0	0.0
4	a	4.0	0.0
5	a	5.0	0.0
6	c	3.0	NaN
7	d	NaN	2.0

	key	data1	data2
0	b	0	1.0
1	b	1	1.0
2	a	2	0.0
3	c	3	NaN
4	a	4	0.0
5	a	5	0.0
6	b	6	1.0

```
# concat() : 리스트 형식으로 들어온 객체를 단순히 연결하는 함수  # 이어붙이려는 개체는 리스트형태여야함
pd.concat([s1, s2, s3])          # 단순 연결, 행으로 추가(axis=0 생략)
pd.concat([s1, s2, s3], axis=1)  # 단순 연결, 열로 추가
```

```
s1
a    0
b    1
dtype: int64

s2
c    2
d    3
e    4
dtype: int64

s3
f    5
g    6
dtype: int64
```

```
a    0
b    1
c    2
d    3
e    4
f    5
g    6
```

	0	1	2
a	0.0	NaN	NaN
b	1.0	NaN	NaN
c	NaN	2.0	NaN
d	NaN	3.0	NaN
e	NaN	4.0	NaN
f	NaN	NaN	5.0
g	NaN	NaN	6.0

05. 집계함수(GroupBy)

```
# 집계함수의 절차 : 분리(split)-적용(apply)-결합(combine)
df = pd.DataFrame({'key1':list('aabba'),
                   'key2':['one','two','one','two','one'],
                   'data1':np.random.randn(5),
                   'data2':np.random.randn(5)})
```

	key1	key2	data1	data2
0	a	one	-0.301045	0.900435
1	a	two	-1.413850	0.340896
2	b	one	1.305095	1.966725
3	b	two	-1.369326	0.096171
4	a	one	0.500293	0.290949

```
df['data1'].groupby(df['key1']).mean()
df.groupby(['key1'])['data1'].mean()
```

key1열의 같은 행들에 대해 data1의 평균

```
key1
a    0.990007
b   -1.062996
```

```
df.groupby(['key1', 'key2']).mean()
```

여러개는 묶어서 (vector)

key1열로 분류 - 이름, 그룹 출력

```
for name, group in df.groupby('key1'):
    print(name); print(group)
```

```
a
  key1 key2     data1     data2
0    a  one  1.857145 -1.283973
1    a  two  1.169426 -0.701425
4    a  one -0.056551 -1.823926
b
  key1 key2     data1     data2
2    b  one -1.543283 -1.465086
3    b  two -0.582708  0.214430
```

key1,key2열로 분류 - 키값, 그룹 출력

```
for (k1, k2), group in df.groupby(['key1', 'key2']):
    print(k1, k2); print(group)
```

```
a one
  key1 key2     data1     data2
0    a  one -0.893977 -1.296604
4    a  one  1.454044  0.788926
a two
  key1 key2     data1     data2
1    a  two  1.324021  2.421498
b one
  key1 key2     data1     data2
2    b  one -0.706422  0.101698
b two
  key1 key2     data1     data2
3    b  two  1.757961 -1.305872
```

개수

```
df.groupby(['key1', 'key2']).count()
```

		data1	data2
key1	key2		
a	one	2	2
	two	1	1
b	one	1	1
	two	1	1

06. 데이터 전처리

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
```

불러오기

```
titanic = sns.load_dataset('titanic')
```

자료 정보확인

```
titanic.info()
```

missingno

```
# 아나콘다 프롬프트 관리자 - pip install missingno
import missingno as msno
msno.matrix(titanic)
plt.show()

msno.bar(titanic)
plt.show()
```

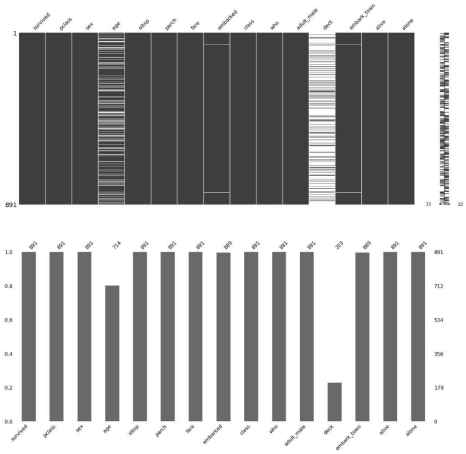

열 삭제

```
# 데이터가 절반 이상이 없는 열을 삭제
titanic = titanic.dropna(thresh=int(len(titanic)*0.5), axis=1)
```

결측값 메꾸기

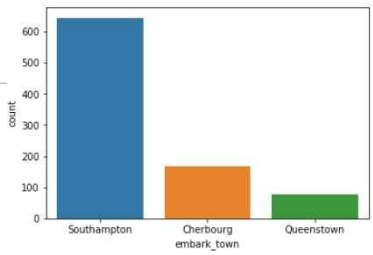


```
# 범주형 데이터는 최빈값으로 대체함 most_frequent
sns.countplot(titanic.embark_town)
plt.show()

from sklearn.impute import SimpleImputer
imputer = SimpleImputer(strategy= 'most_frequent')  # 최빈값으로 결측값 채우기
titanic['embark_town'] = imputer.fit_transform(titanic[['embark_town']])
titanic['embarked'] = imputer.fit_transform(titanic[['embarked']]) # 2차원 배열처럼 써줘야함..
```

```
sns.kdeplot(titanic.age)  # 밀도함수 -> 중앙값 확인
plt.show()

imputer_age = SimpleImputer(strategy= 'median')  # 중앙값으로 채우기
titanic['age'] = imputer_age.fit_transform(titanic[['age']])
```

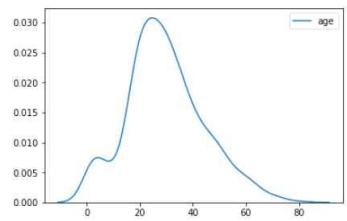

결측 데이터수 확인

```
titanic.isnull().sum()  # 결측데이터 수
```

피처(컬럼, 열) 제거

```
# 불필요한 피처를 제거하는 작업
df_titanic = titanic.drop(['class','alive','who','embarked', 'embark_town'], axis=1)
```

데이터 확인

```
df_titanic.head()
```

	survived	pclass	sex	age	sibsp	parch	fare	adult_male	alone
0	0	3	male	22.0	1	0	7.2500	True	False
1	1	1	female	38.0	1	0	71.2833	False	False
2	1	3	female	26.0	0	0	7.9250	False	True
3	1	1	female	35.0	1	0	53.1000	False	False
4	0	3	male	35.0	0	0	8.0500	True	True

데이터 시각화

```
# 등급별 고객정보, 각 개체별 건수
df_titanic['pclass'].value_counts()
(1-2-3 : 객실등급)
```

```
3    491
1    216
2    184
```

```
df_titanic['survived'].value_counts().plot.bar()
(0 : 사망, 1 : 생존)
```

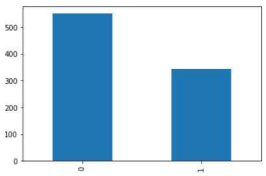

```
df_titanic['pclass'].value_counts().plot.bar()
```

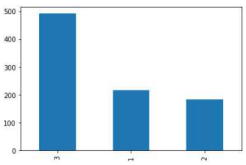

```
ax = sns.countplot(x='pclass', data=df_titanic)
```

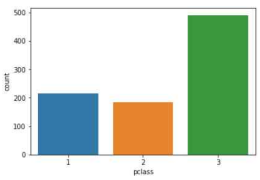


```
ax = sns.countplot(x='pclass', hue='survived', data=df_titanic)
```

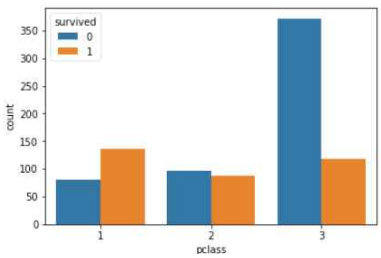


```
ax = sns.countplot(x='sex', hue='survived', data=df_titanic)
```

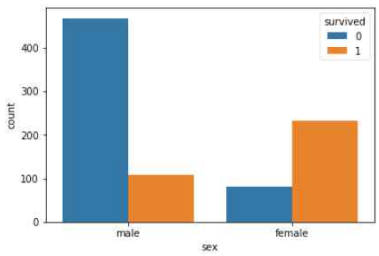


```
ax = sns.countplot(x='alone', hue='survived', data=df_titanic)
```